

CardioIA Acolhe - IR ALÉM 1

IA generativa aplicada à extração de informações clínicas a partir de texto livre

FLASK	CHAT COMPLETIONS (OPENAI-COMPATÍVEL)	JSON MODE	FEW-SHOT + CHAIN-OF-THOUGHT
-------	--------------------------------------	-----------	-----------------------------

Objetivo

O IR ALÉM 1 expande o assistente para **interpretar relatos clínicos não estruturados**: uma pessoa escreve livremente o que sente e um modelo de linguagem devolve a mesma informação **organizada em JSON** - sintoma, intensidade de 0 a 10, duração, contexto, entidades nomeadas, nível de alerta e confiança. O módulo é um serviço Python independente (`src/backend/clinical_extractor.py`), exposto pela API Flask e integrado ao fluxo conversacional do Watson Assistant já entregue na Parte 1.

LIMITES CLÍNICOS

O modelo apenas extrai e organiza o que foi relatado: não diagnostica, não prescreve e não recomenda medicamentos. A orientação de emergência (SAMU 192) é decidida pelo backend a partir do nível de alerta, nunca pelo modelo. Todos os textos usados no projeto são fictícios.

Fluxo de extração



1. O texto é validado (não vazio, até 2.000 caracteres na API) e normalizado. 2. O backend monta duas mensagens: um *system prompt* com papel, regras e esquema de saída, e uma mensagem de usuário com os exemplos *few-shot*, os passos de raciocínio e o texto a analisar. 3. A API Chat Completions (protocolo da OpenAI, aceito também por Google Gemini, Groq e outros) é chamada com `response_format={"type": "json_object"}`, temperatura 0,2 e limite de 4.000 tokens (modelos com raciocínio interno, como o Gemini 3.x, gastam parte do orçamento antes de escrever o JSON), o que força uma resposta JSON estável. 4. A resposta é convertida e validada: inteiros são limitados a 0-10, confianças a 0,0-1,0, a severidade é mapeada para um *enum* e valores ausentes recebem padrões seguros. 5. O objeto `ClinicalExtraction` é serializado e devolvido pela API.

Técnicas de prompting aplicadas

Técnica	Como foi aplicada	Onde está
System prompt com papel e regras	Define o papel de assistente de PLN clínica, dez regras explícitas (não diagnosticar, escalas numéricas, critérios de severidade, valores ausentes) e o esquema JSON esperado.	SYSTEM_PROMPT
Few-shot learning	Quatro exemplos completos - <i>critical</i> , <i>high</i> , <i>moderate</i> e <i>info</i> - com entidades, normalização e justificativa, cobrindo todos os caminhos do fluxo.	FEW_SHOT_EXAMPLES
Chain-of-thought	Seis passos ordenados que o modelo segue antes de responder; a justificativa fica registrada no campo <code>reasoning</code> . 1. Identifique o sintoma principal (ou registre que não há sintoma). 2. Estime a intensidade de 0 a 10 a partir das palavras usadas. 3. Localize a duração e o contexto (quando, onde, o que estava fazendo). 4. Procure sinais de alerta: dor no peito, suor frio, falta de ar em repouso, desmaio. 5. Classifique a severidade conforme as regras. 6. Liste entidades nomeadas e atribua a confiança geral.	COT_STEPS
Saída estruturada (JSON mode)	Temperatura baixa, limite de tokens e <code>json_object</code> garantem JSON sintaticamente válido em todas as chamadas.	ClinicalExtractor.extract
Validação pós-modelo	Normaliza tipos, faixas, enum de severidade e tipos de entidade; nunca confia cegamente no texto gerado.	parse_extraction

Estrutura da saída

Um esquema único para o modelo, a validação, a API e os testes

Campo	Tipo	Descrição
symptom	string	Sintoma principal relatado ou "nenhum sintoma relatado".
intensity	inteiro 0-10	Intensidade estimada a partir das palavras usadas; 0 quando não há sintoma.
duration	string	Duração ou frequência descrita; "não informado" quando ausente.
context	string	Circunstâncias: momento, atividade, sinais associados.
alert_severity	enum	critical, high, moderate, low ou info - decide a ação do backend.
confidence	número 0,0-1,0	Confiança geral do modelo na extração.
entities	lista	Entidades nomeadas: value, type (symptom, medication, condition, duration, context, other), confidence, normalized.
reasoning	string	Justificativa curta produzida pelo passo de chain-of-thought.

Exemplo reproduzível

Entrada fictícia: *"Acordei ontem à noite com uma dor forte no peito, tipo um aperto. Suei muito frio. Durou uns 30 minutos e achei que ia morrer."*

```
{
  "symptom": "dor forte no peito em aperto e suor frio",
  "intensity": 9,
  "duration": "aproximadamente 30 minutos",
  "context": "ao acordar ontem à noite, com sensação de morte iminente",
  "alert_severity": "critical",
  "confidence": 0.98,
  "entities": [
    {"value": "dor forte no peito", "type": "symptom", "confidence": 0.98, "normalized": "dor torácica"},
    {"value": "aperto", "type": "symptom", "confidence": 0.95, "normalized": "dor em aperto"},
    {"value": "Suei muito frio", "type": "symptom", "confidence": 0.97, "normalized": "sudorese fria"},
    {"value": "30 minutos", "type": "duration", "confidence": 0.95, "normalized": null},
    {"value": "achei que ia morrer", "type": "symptom", "confidence": 0.92, "normalized": "sensação de morte iminente"},
    {"value": "ontem à noite", "type": "context", "confidence": 0.9, "normalized": null}
  ],
  "reasoning": "O relato descreve dor torácica de forte intensidade em aperto, associada a sudorese fria e sensação de morte iminente, o que configura um quadro de alta suspeita para emergência cardiovascular (infarto agudo do miocárdio)."
}
```

Saída real do modelo **gemini-3.5-flash** (provedor google) em 14/09/2026, gravada por python scripts/demo_clinical_extractor.py --real --save em document/ir-alem-1-evidencia-llm.json. Sem chave, o mesmo comando devolve o esquema idêntico no modo de simulação.

Integração com o assistente conversacional

Método	Rota	Contrato essencial
POST	/api/extract	text → extraction (JSON acima), model e mode. 400 para entrada inválida; 502 se o modelo falhar.
POST	/api/chat/clinical	message + conversationId → mesmo contrato de /api/chat (reply, intent, entities, urgent) mais clinical e source.
GET	/api/health	Inclui clinical.mode (mock ou llm), clinical.provider e clinical.model, sem expor segredos.

Nível de alerta	Critério	Comportamento de /api/chat/clinical
critical	Dor torácica com sinais de alerta, falta de ar em repouso, desmaio.	Responde imediatamente com orientação de emergência (urgent: true) sem consultar o Watson.
high, moderate, low, info	Demais relatos, perguntas e saudações.	O Watson responde e a extração é anexada em clinical; se o Watson não estiver configurado ou falhar, o backend devolve uma resposta educativa local construída a partir da extração.

Anatomia do prompt

O que o modelo recebe em cada chamada, exatamente como está no código

Mensagem de sistema (papel, regras e esquema)

```

Você é um assistente de processamento de linguagem natural clínica do CardioIA Acolhe.
Sua única tarefa é EXTRAIR e ORGANIZAR informações de relatos livres de sintomas cardiológicos.

REGRAS OBRIGATÓRIAS:
1. Você NÃO diagnostica, NÃO prescreve e NÃO recomenda medicamentos. Apenas extrai o que foi relatado.
2. "intensity" é um inteiro de 0 a 10 (0 = nenhum sintoma; 10 = o pior possível).
3. "alert_severity" deve ser exatamente um de: "critical", "high", "moderate", "low", "info".
4. "confidence" é um número de 0.0 a 1.0 que expressa a sua confiança na extração.
5. Sinais de alerta que tornam o caso "critical": dor ou aperto no peito com intensidade alta, dor no peito acompanhada de suor frio, falta de ar em repouso, desmaio ou síncope.
6. Falta de ar ao esforço, dor no peito leve ou palpitações com mal-estar: "high".
7. Palpitações isoladas, cansaço ou tontura sem outros sinais: "moderate" ou "low".
8. Perguntas, saudações ou mensagens sem sintoma: "info", com "intensity" 0.
9. Quando uma informação não aparecer no texto, escreva "não informado" no campo correspondente.
10. Extraia entidades nomeadas com "type" em: symptom, medication, condition, duration, context, other.

FORMATO DE SAÍDA (JSON válido, sem texto fora do JSON):
{
  "symptom": "string",
  "intensity": 0,
  "duration": "string",
  "context": "string",
  "alert_severity": "critical|high|moderate|low|info",
  "confidence": 0.0,
  "entities": [
    { "value": "string", "type": "symptom|medication|condition|duration|context|other",
      "confidence": 0.0, "normalized": "string ou null" }
  ],
  "reasoning": "explicação breve do raciocínio"
}
```

Mensagem de usuário (few-shot + chain-of-thought + texto)

Montada por build_extraction_prompt: os quatro exemplos few-shot no formato abaixo, os seis passos de raciocínio da página 1 e o texto a analisar entre aspas, encerrando com "Responda APENAS com o JSON". Exemplo 2, como enviado:

```

Texto: "Falta de ar ao subir as escadas. Normal cansaço ou algo preocupante? Aconteceu por uns 10 minutos."
Saída JSON:
{
  "symptom": "falta de ar ao esforço",
  "intensity": 6,
  "duration": "10 minutos",
  "context": "durante atividade física (subir escadas)",
  "alert_severity": "high",
  "confidence": 0.88,
  "entities": [
    { "value": "falta de ar", "type": "symptom", "confidence": 0.95, "normalized": "dispneia" },
    { "value": "subir as escadas", "type": "context", "confidence": 0.9, "normalized": "esforço físico" },
    { "value": "10 minutos", "type": "duration", "confidence": 0.9, "normalized": null }
  ],
  "reasoning": "Dispneia ao esforço sem suor frio ou desmaio: requer avaliação, mas não é emergência imediata."
}
```

Evidência de execução real

Cenários da demo enviados ao modelo **gemini-3.5-flash** (provedor google) em 14/09/2026; JSON completo em document/ir-alem-1-evidencia-llm.json. O provedor foi usado só nesta verificação: qualquer API compatível serve, trocando LLM_BASE_URL e LLM_MODEL.

Cenário	Nível	Int.	Conf.	Sintoma extraído	Entidades por tipo
Emergência (dor torácica)	critical	9	0.98	dor forte no peito em aperto e suor frio	4 symptom, 1 duration, 1 context
Alerta alto (falta de ar ao esforço)	high	7	0.95	falta de ar ao esforço	1 symptom, 3 context, 1 duration
Moderado (palpitações recorrentes)	moderate	4	0.95	palpitações	1 symptom, 2 duration, 1 medication
Sem sintoma (pergunta educativa)	info	0	0.95	nenhum sintoma relatado	-

Confiabilidade e reprodução

Falhas seguras, dois modos de execução, comandos de reprodução e testes automatizados

Tratamento de erros e privacidade

Situação	Comportamento
Texto vazio ou acima do limite	ValueError no módulo; 400 na API, antes de qualquer chamada ao modelo.
Falha de rede, chave inválida ou cota esgotada	Erro do SDK encapsulado em ClinicalExtractionError com mensagem neutra; 502 em /api/extract; /api/chat/clinical segue com o Watson.
Resposta não JSON, vazia ou com estrutura errada	Mesmo tratamento seguro; o conteúdo bruto nunca é devolvido ao cliente.
Campos ausentes ou fora da faixa	Padrões seguros (intensidade 0, confiança 0,5, severidade moderate) e limites aplicados.
Privacidade	Nenhum texto clínico, resposta do modelo ou credencial é registrado em log; o campo raw_model_output não sai da API; chave apenas em .env ignorado pelo git.

Modos de execução

Modo	Quando é usado	Características
mock	Sem LLM_API_KEY (padrão em testes e CI).	Simulação determinística por palavras-chave com o mesmo esquema e as mesmas regras de severidade; sem rede e sem custo.
llm	Com LLM_API_KEY no .env.	Chat Completions no provedor de LLM_BASE_URL e modelo de LLM_MODEL (padrão gpt-4o-mini); JSON mode, temperatura 0,2, timeout 20 s. Verificado com o Google Gemini (free tier) apenas por conveniência: OpenAI, Groq ou qualquer API compatível funcionam sem alterar código.

Como executar

```
python -m venv .venv; .\.venv\Scripts\Activate.ps1
python -m pip install -r requirements.txt
Copy-Item .env.example .env # opcional: LLM_API_KEY (+ LLM_BASE_URL / LLM_MODEL)
python scripts/demo_clinical_extractor.py # 4 cenários no modo mock
python scripts/demo_clinical_extractor.py --real # usa o provedor do .env (Gemini, OpenAI...)
python scripts/demo_clinical_extractor.py --real --save document/ir-alem-1-evidencia-llm.json
python -m src.backend # API em http://127.0.0.1:5000
curl -X POST http://127.0.0.1:5000/api/extract -H "Content-Type: application/json" -d '{"text": "Falta de ar ao subir escadas, uns 10 minutos"}'
```

Testes automatizados

Arquivo	Testes	Cobertura
tests/backend/test_clinical_extractor.py	51	Conteúdo do prompt, exemplos few-shot, parsing e limites, extrator real com cliente falso, provedores, mock e fábricas.
tests/backend/test_clinical_api.py	23	/api/extract e /api/chat/clinical: validação, severidade crítica, anexo ao Watson, degradação sem Watson, erros 502/503 sem vazamento.
Suíte original (API, gateway e export)	42	Inalterada; o health passou a informar o modo do extrator.
Total	116	116/116 aprovados em 14/09/2026 com Python 3.11.9

Limites e próximos passos

O extrator trabalha apenas com texto; imagens simuladas não fazem parte desta entrega. A qualidade com modelo real depende do provedor escolhido e não foi medida com um conjunto anotado: o critério de aceitação foi o esquema válido e a coerência com as regras de severidade. Próximos passos: medir precisão em relatos fictícios rotulados, ligar a interface React a /api/chat/clinical e persistir extrações para o IR ALÉM 2.

Referências. OpenAI - [Structured outputs / JSON mode](#). Google - [Gemini API: OpenAI compatibility](#). Brown et al. (2020) - *Language Models are Few-Shot Learners*. Wei et al. (2022) - *Chain-of-Thought Prompting Elicits Reasoning in Large Language Models*. Ministério da Saúde - [SAMU 192](#).